

21 יקום גמטי

2.11 אלגוריתם סקאלרי

$$A = \begin{bmatrix} 1 & 1 & 0 \\ 1 & -1 & 2 \end{bmatrix}$$

① נעשה את ה SVD של המטריצה הזו

$$A^T A = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} 1 & 1 & 0 \\ 1 & -1 & 2 \end{bmatrix} = \begin{bmatrix} 2 & 0 & 2 \\ 0 & 2 & -2 \\ 2 & -2 & 4 \end{bmatrix}$$

המטריצה, נטולת

נמצא את הערכים של $A^T A$

$$\det(A^T A - \lambda I) = 0 \Rightarrow \begin{vmatrix} 2-\lambda & 0 & 2 \\ 0 & 2-\lambda & -2 \\ 2 & -2 & 4-\lambda \end{vmatrix} = 0 \Rightarrow \lambda(\lambda-4)(\lambda-6) = 0 \Rightarrow \lambda = 0, 2, 6$$

נמצא את הערכים של $\lambda = 4, 6$

$$(A^T A - 0I)V = 0 \Rightarrow \begin{bmatrix} 2 & 0 & 2 \\ 0 & 2 & -2 \\ 2 & -2 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = 0 \Rightarrow \begin{bmatrix} 2x_1 & 0 & 2x_3 & 0 \\ 0 & 2x_1 & -2x_3 & 0 \\ 2x_1 & -2x_2 & 4x_3 & 0 \end{bmatrix} \Rightarrow \begin{bmatrix} x_1 & 0 & x_3 & 0 \\ 0 & x_1 & -x_3 & 0 \\ x_1 & -x_2 & 2x_3 & 0 \end{bmatrix} \Rightarrow \begin{matrix} x_1 = -x_3 \\ x_2 = x_3 \\ x_3 = x_3 \end{matrix} \Rightarrow V_0 = \begin{pmatrix} -1 \\ 1 \\ 1 \end{pmatrix}$$

$$\|V\| = \sqrt{\langle V, V \rangle} = \sqrt{3}$$

נבחר את הערך של $\lambda = 4, 6$ ונמצא את הערכים של $\lambda = 4, 6$

$$V_0^T = \left(-\frac{1}{\sqrt{3}}, \frac{1}{\sqrt{3}}, \frac{1}{\sqrt{3}}\right)$$

אם

$$(A^T A - 2I)V = 0 \Rightarrow \begin{bmatrix} 0 & 0 & 2 \\ 0 & 0 & -2 \\ 2 & -2 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = 0 \Rightarrow \begin{bmatrix} 0 & 0 & 2x_3 & 0 \\ 0 & 0 & -2x_3 & 0 \\ 2x_1 & -2x_2 & 2x_3 & 0 \end{bmatrix} \Rightarrow \begin{bmatrix} 0 & 0 & x_3 & 0 \\ 0 & 0 & -x_3 & 0 \\ x_1 & -x_2 & x_3 & 0 \end{bmatrix} \Rightarrow \begin{matrix} x_1 = x_2 \\ x_3 = 0 \end{matrix} \Rightarrow V = \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}$$

$$\|V_1\| = \sqrt{\langle V_1, V_1 \rangle} = \sqrt{2}$$

נבחר את הערך של $\lambda = 4, 6$ ונמצא את הערכים של $\lambda = 4, 6$

$$V_1^T = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}, 0\right)$$

אם

$$(A^T A - 6I)V = 0 \Rightarrow \begin{bmatrix} -4 & 0 & 2 \\ 0 & -4 & -2 \\ 2 & -2 & -2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = 0 \Rightarrow \begin{bmatrix} -4x_1 & 0 & 2x_3 & 0 \\ 0 & -4x_1 & -2x_3 & 0 \\ 2x_1 & -2x_2 & -2x_3 & 0 \end{bmatrix} \Rightarrow \begin{bmatrix} -2x_1 & 0 & x_3 & 0 \\ 0 & 2x_1 & x_3 & 0 \\ x_1 & -x_2 & -x_3 & 0 \end{bmatrix} \Rightarrow \begin{matrix} x_1 = \frac{1}{2}x_3 \\ x_2 = -\frac{1}{2}x_3 \end{matrix} \Rightarrow V = \begin{pmatrix} 1 \\ -1 \\ 2 \end{pmatrix}$$

$$\|V_2\| = \sqrt{\langle V_2, V_2 \rangle} = \sqrt{1+1+4} = \sqrt{6}$$

נבחר את הערך של $\lambda = 4, 6$ ונמצא את הערכים של $\lambda = 4, 6$

$$V_2^T = \left(\frac{1}{\sqrt{6}}, -\frac{1}{\sqrt{6}}, \frac{2}{\sqrt{6}}\right)$$

אם

$$V = \begin{bmatrix} \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{3}} \\ -\frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \\ \frac{2}{\sqrt{6}} & 0 & \frac{1}{\sqrt{3}} \end{bmatrix}$$

$$\Sigma = \begin{bmatrix} \sqrt{6} & 0 & 0 \\ 0 & \sqrt{2} & 0 \end{bmatrix}$$

נמצא את הערכים של $\lambda = 4, 6$ ונמצא את הערכים של $\lambda = 4, 6$

אם $\lambda = 0$ נמצא את הערכים של $\lambda = 4, 6$ ונמצא את הערכים של $\lambda = 4, 6$

$$AA^T = \begin{bmatrix} 1 & 1 & 0 \\ 1 & -1 & 2 \\ 0 & 2 & 2 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 0 & 2 \end{bmatrix} = \begin{bmatrix} 2 & 0 \\ 0 & 6 \end{bmatrix}$$

באמצעות AA^T נמצא את הערכים העigen של A .
הערכים העigen של AA^T הם 2 ו- 6 .

$$\det(AA^T - \lambda I) = 0 \Rightarrow \begin{vmatrix} 2-\lambda & 0 \\ 0 & 6-\lambda \end{vmatrix} = 0 \Rightarrow (2-\lambda)(6-\lambda) = 0 \Rightarrow \lambda = 2, 6$$

לכן, נמצא את הערכים העigen של A .

$$(AA^T - 2I)U = 0 \Rightarrow \begin{bmatrix} 0 & 0 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0 \Rightarrow \begin{bmatrix} 0 & 0 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0 \Rightarrow x_2 = 0 \Rightarrow U_2 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

$$U_2^T = (1 \ 0)$$

הערכים העigen של A הם 1 ו- 0 .

$$(AA^T - 6I)U = 0 \Rightarrow \begin{bmatrix} -4 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0 \Rightarrow x_1 = 0 \Rightarrow U_6 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

הערכים העigen של A הם 1 ו- 0 .

$$U = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$$

לכן

$$A = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{3}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \\ \frac{2}{\sqrt{6}} & 0 & \frac{1}{\sqrt{3}} \end{bmatrix} \begin{bmatrix} \sqrt{6} & 0 & 0 \\ 0 & \sqrt{2} & 0 \end{bmatrix} \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$$

לכן

נמצא את הערכים העigen של A .

לכן

$$V \otimes U = V \times U^T = \begin{pmatrix} U_1 \\ \vdots \\ U_n \end{pmatrix} (U_1 \dots U_m) = \begin{pmatrix} U_1 U_1 & \dots & U_1 U_m \\ \vdots & & \vdots \\ U_n U_1 & \dots & U_n U_m \end{pmatrix} \in \mathbb{R}^{n \times m}$$

הערכים העigen של A הם 1 ו- 0 .

לכן, נמצא את הערכים העigen של A .

$$R_i = (U_i \cdot U_1, U_i \cdot U_2, \dots, U_i \cdot U_m) = U_i \cdot (U_1, \dots, U_m) = U_i \cdot U \Rightarrow$$

לכן, נמצא את הערכים העigen של A .

$$C_j^T = (U_1 U_j, \dots, U_n U_j) = U_j (U_1, \dots, U_n) = U_j \cdot U \Rightarrow$$

לכן, נמצא את הערכים העigen של A .

③ לבדוק מה צריך להוסיף. יהי $V = \mathbb{R}^n$ ו- $U = (u_1 \dots u_n)$ בסיס.
 אחרת נניח V . \exists סדר ויף כי כלשהו $X \in \mathbb{R}^n$ כלשהו.

$$X = \sum_{i=1}^n \alpha_i u_i$$
 נ

$$X = \sum_{i=1}^n \langle X, u_i \rangle u_i$$
 כלומר $\langle X, u_i \rangle = \alpha_i$

נכ"ל:

$$\sum_{i=1}^n \langle X, u_i \rangle u_i = \sum_{i=1}^n \langle \sum_{j=1}^n \alpha_j u_j, u_i \rangle u_i = \sum_{i=1}^n \sum_{j=1}^n \alpha_j \langle u_j, u_i \rangle u_i = \sum_{i=1}^n \alpha_i u_i = X$$

\uparrow גזירה X
 \uparrow גזירה X
 מכיון ש u בסיס אורתונורמלי.
 הנכנסה הפנימית נתן 0 בזה המקרה
 בהם $j \neq i$ או במקרה בו $j=i$.
 אז רק בזה $j=i$ מתקיי $\langle u_j, u_i \rangle = \langle u_i, u_i \rangle = 1$
 $= \alpha_i u_i$

(4) $\underline{k} \in \tilde{\beta} \cap P$ יהא כזה שיהיו:

$\sum_{i=1}^n (v_i^T v_i) = \sum_{i=1}^n v_i^T v_i$

$P'' \preceq N$ ist $V_i \in V$ „i“

לכיוון המזרח הדרומי
עם זווית של 1 אלף
j = 10° או 100° (זווית
המזרח הדרומי).

• $\rho_{v_i} = v_i$, NIG

$\rho \in \mathbb{R}^n$ $\rho \in \mathbb{R}^n$ $\rho \in \mathbb{R}^n$

1. $\Gamma \vdash V \wedge V$ "1" \leq

באי שר ϵ P_u מיושם זרה דה/ינתן בטלה 3-פר.

$$p^2 = p \quad \sqrt[3]{3} = \underline{\underline{3}}$$

$\begin{cases} i=j \\ i \neq j \end{cases} \quad \begin{aligned} \langle v_i, v_j \rangle &= 1 \\ \langle v_i, v_j \rangle &= 0 \end{aligned}$

$$(I-P)P = 0$$

הן

$$(I-P)P = IP - P^2 = IP - P = P - P = 0$$

\nearrow
 $P^2 = P$

2.1.2 הפרדת המרחב

$$h(\sigma) = \frac{1}{2} \|f(\sigma) - y\|^2 = \frac{1}{2} \|f(\sigma)\|^2 - f(\sigma)^T y + \frac{1}{2} \|y\|^2 \quad \text{דאג' (5)}$$

$$\begin{aligned} \frac{\partial h}{\partial \sigma_i} &= \frac{\partial h}{\partial f} \cdot \frac{\partial f}{\partial \sigma_i} = \frac{\partial}{\partial f} \cdot \left(\frac{1}{2} \|f(\sigma)\|^2 - f(\sigma)^T y + \frac{1}{2} \|y\|^2 \right) \frac{\partial f}{\partial \sigma_i} \\ &= \left(\frac{1}{2} \cdot 2 f(\sigma) - y \right) \frac{\partial f}{\partial \sigma_i} = (f(\sigma) - y) \frac{\partial f}{\partial \sigma_i} = (*) \end{aligned}$$

$$\frac{\partial f}{\partial \sigma_i} = \int_{\sigma} (f)$$

כל המרחב

$$(*) = (f(\sigma) - y) \cdot \int_{\sigma} (f)$$

נ

$$: S \text{ מרחב } \mu \text{ מרחב } [J_x(f)]_{ij} = [\nabla f(x)_i]_j = \frac{\partial f_i(x)}{\partial x_j} \quad \text{פונקציה (6)}$$

$$[\nabla S(x)_i]_j = \frac{\partial}{\partial x_j} \cdot \frac{e^{x_i}}{\sum_{k=1}^K e^{x_k}} = \frac{e^{x_i} (\sum_{k=1}^K e^{x_k}) - e^{x_i} e^{x_j}}{(\sum_{k=1}^K e^{x_k})^2}$$

$$[\nabla S(x)_i]_j = \frac{e^{x_i}}{\sum_{k=1}^K e^{x_k}} \cdot \frac{(\sum_{k=1}^K e^{x_k}) - e^{x_j}}{\sum_{k=1}^K e^{x_k}} = S(x)_i (1 - S(x)_j)$$

$i=j$ נכון

$$[\nabla S(x)_i]_j = \frac{0 \cdot \sum_{k=1}^K e^{x_k} - e^{x_i} e^{x_j}}{(\sum_{k=1}^K e^{x_k})^2} = \frac{-e^{x_i}}{\sum_{k=1}^K e^{x_k}} \cdot \frac{e^{x_j}}{\sum_{k=1}^K e^{x_k}} = -S(x)_i S(x)_j \quad : i \neq j$$

$$[\nabla S(x)_i]_j = S(x)_i (1_{i=j} - S(x)_j)$$

כל המרחב

$$J_x(S) = \text{diag}(S) - SS^T$$

המרחב המשותף

2.2.1

1

$U \neq 0$ and $V \in \ker(T)$ then $|\ker(T)| = |\ker(X^T X)| \Rightarrow \sqrt{3}$
 $X^T X U = X^T 0 = 0$ and $X V = 0$ and $V \in \ker(X^T X)$

$U^T X^T X U = 0$ and $X^T X V = 0$ and $V \in \ker(X^T X)$
 $\|XU\|^2 = (XU)^T XU = U^T X^T X U = 0$ and $\|XV\|^2 = (XV)^T XV = V^T X^T X V = 0$



$V \in \ker(X)$ and $XV = 0 \Leftrightarrow \|XV\| = 0$

$\text{Im}(A) \subset \ker(A)^{\perp}$ and $\text{Im}(A^T) = \ker(A)^{\perp}$ and $A \in M_{k \times k}$

$A^T x = b$ and $x \in \mathbb{R}^n$ and $b \in \text{Im}(A^T)$

$0 = \langle A^T w, x \rangle = \langle w, Ax \rangle = \langle w, b \rangle$ and $A^T w = 0$ and $w \in \ker(A^T)$

$\text{Im}(A) \subset \ker(A^T)^{\perp}$

$b \in \ker(A^T)^{\perp}$ and $b \in \text{Im}(A)$ and $\ker(A^T)^{\perp} \subset \text{Im}(A)$
 $b \in \text{Im}(A)^{\perp}$ and $\langle b, a \rangle \neq 0$ and $a \in \ker(A^T)$

$a \in \text{Im}(A)^{\perp}$ and $\langle b, a \rangle \neq 0$ and $a \in \text{Im}(A)^{\perp}$

$\langle 0, AA^T a \rangle = 0$ and $V \in \text{Im}(A)$ and $\langle 0, AA^T a \rangle = 0$

$\|A^T a\|^2 = \langle A^T a, A^T a \rangle = \langle a, AA^T a \rangle = 0$

$a \in \ker(A^T)$ and $A^T a = 0$ and $a \in \ker(A^T)$



2

$$[X^T X]^{-1} X^T = \left[(U \Sigma V^T)^T (U \Sigma V^T) \right]^{-1} (U \Sigma V^T)^T = \left[V \Sigma^T U^T U \Sigma V^T \right]^{-1} V \Sigma^T U^T$$

\uparrow $X = U \Sigma V^T$ \uparrow U אורתוגונל

$$= \left[V \Sigma^T \Sigma V^T \right]^{-1} V \Sigma^T U^T = V (\Sigma^T \Sigma)^{-1} \cancel{V^T} \Sigma^T U^T = V (\Sigma^T \Sigma)^{-1} \Sigma^T U^T$$

\uparrow U אורתוגונל

$$A = \Sigma^T \Sigma$$

אם A סימטרית

$$= V A^{-1} \Sigma^T U^T$$

$$A_{ii} = (\sigma_i)^2$$

כאשר σ_i הסיגמא ה- i של A (הערכים העצמיים של A)

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_n > 0$$

כאשר σ_i הסיגמא ה- i של A (הערכים העצמיים של A)

$$A^{-1} = \frac{1}{\sigma_i^2}$$

כאשר σ_i הסיגמא ה- i של A (הערכים העצמיים של A)

$$[A^{-1} \Sigma^T]_{ii} = \frac{1}{(\sigma_i)^2} \cdot \sigma_i = \frac{1}{\sigma_i} = \Sigma_{ii}^{-1}$$

$$[X^T X]^{-1} X^T y = V \Sigma^+ U^T y = X^+ y$$

$$y \in \mathbb{R}^n$$

כאשר y וקטור בעל n רכיבים



3. מ/א/ק טיקי

3.1.3 הסבר נרחב לתהליך העיבוד המקדים של המידע שהתקבל לגבי מחירי בתים:

ראשית, בחרתי להוריד כל פיצ'ר שלא נותן לי מידע כלשהו שתורם מידע לגבי סכום המכירה, כלומר, כל פיצ'ר שבמבט פשוט אינו קשור ישירות אל סכום המכירה. פיצ'רים כמו ID, lat' long אשר בהבנה פשוטה לא תרמו לי כל מידע נוסף לגבי המכירה.


בנוסף, הפכתי את המידע על שנת השיפוץ לקטגוריאל- האם הבית שופץ מאז בנייתו או לא. כמו כן, המרתי את date, year built לפיצ'ר יחיד שקבע בן כמה היה הבית ברגע מכירתו.

כמו כן, בחרתי להפוך למשתנה קטגוריאל את הפיצ'ר המייצג את הבית שופץ או לא, ובחרתי להשאיר כמשתנים קטגוריאלים אשר להם סולם מדידה איכותי את הפיצ'רים אשר המידע לגביהם הוצג בצורה קטגוריאלית- פיצ'רים כמו waterfront, view, grade וכו'.

החשיבה שעמדה מאחורי הפיכת את תאריך המכירה ותהאריך בניית הבית למשתנה יחיד שמייצג את גיל הבית בעת מכירתו נבע מכך שחשבתי שמדד זה ישקף ביתר בהירות מידע על מחיר הבית או יתן למודל מידע שיעזור לו לחזות את מחיר הבית בצורה טובה יותר. ההנחה שלי הייתה שמשתנה יחיד כמו זה משקף נתונים אלו בצורה בהירה יותר מאשר שנת המכירה או שנת הבנייה.

בנוסף, עברתי על datan כולו ומחקתי ערכים שגויים וערכי nan הן ממטריצת הפיצ'רים והן מוקטור מחירי הבתים. (X,y בהתאמה).


3.1.4 בחרתי להביא את גרפי הקורלציה של הפיצ'רים הבאים:



מדד הקורלציה של sq ft living ניתן לראות בקלות כי קיימת מגמה בגרף, וככל שגודל שטח המגורים גדל גם מחיר הבית. דבר זה מתבטא גם בציון הקורלציה הגבוה של פיצ'ר זה- מעל 0.7. דבר זה גורם לכך שפיצ'ר זה מיטבי עבור המודל ומספק לו מידע 'חיוני' המסייע לו לדעת לחזות את מחיר הבית.

מדד הקורלציה של house age.

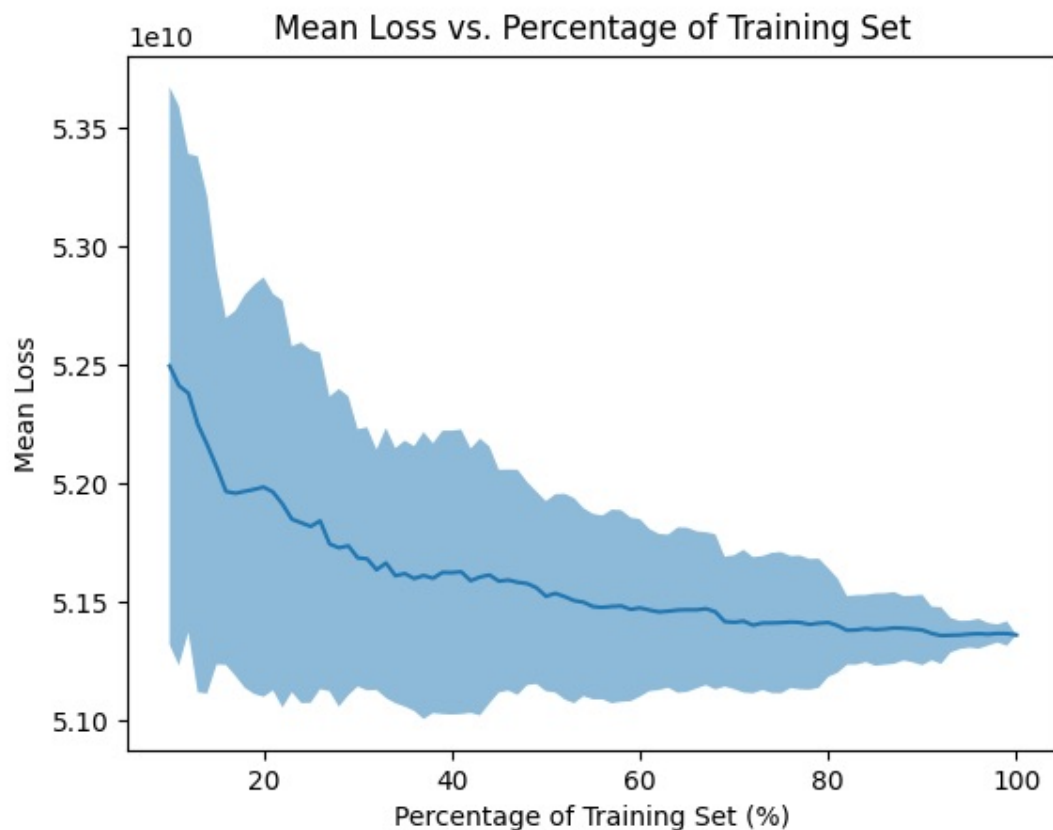
בשונה מהגרף הקודם, גרף הקורלציה עבור מחיר הבית אינו מיטבי עבור המודל. ניתן לראות כי אי אפשר לזהות מגמה כלשהי בגרף. כלומר, גיל הבית אינו מעיד בהכרח על מחיר גבוה או נמוך של הבית. דבר שמתבטא גם בצן קורלציה נמוך- מתחת ל0.05. לכן, פיצ'ר זה אינו 'תורם' הרבה מידע חיוני למודל ומסייע לו לחזות מחירי בתים.



3.1.6 הגרף המוצג מטה מציג את מדד Loss כתלות בגודל training set.


ניתן בנקל לראות כי ככל שגודל training set גדול יותר כך גודל loss (המייצג את מספר ה'שגיאות' בהן שגה המודל) קטן. כלומר, ככל שגודל הנתונים עליהם המודל 'מתאמן' כך מספר השגיאות שלו פוחת בהתאמה.

כמו כן, ניתן לראות כי ככל שגודל training set עולה, כך ה'איזור התכול' מסביב לקו המרכזי מתמרכז ומתקרב לקו המרכזי. איזור זה מייצג את confidence integral של המודל, כלומר, את אומדן אי הוודאות של המודל. ניתן לראות כי ככל שגודל training set עולה כך איזור זה נהיה קרוב יותר אל הקו המרכזי, דבר המעיד על כך שהמודל מציד תוצאות יותר קונסטנטיביות ויותר קרובות לפתרון נכון.




3.2.3 הגרף המוצג מטה מציג פיזור של טמפ' יומיות ממוצעות בישראל לפי יום בשנה. הגרף מציג מגמה ברורה של עלייה בטמפ' במהלך האביב, הגעה לשיא בקיץ ואז ירידה בסתיו עד לחורף.

מתוצרת הנתונים נראה שהפוליון הוא מדרגה הדומה לפוליון מדרגה שנייה או שלישית, ולכן יכול להיות שקיים פוליון ממעלה כזו היכול לתאר מגמה כללית של הגרף בצורה קרובה (יחסית) לגרף המקורי.



הגרף המוצג מטה מציג את סטיית התקן של הטמפ' היומיות לפי חודשי השנה בישראל. ניתן לראות כי קיימת שונות בסטיית התקן בין חודשי השנה בישראל. על בסיס הגרף, ניתן לצפות שמודל פוליון לחיזוי טמפ' יצליח טוב יותר בחודשין 4-9 מאשר בשאר חודשי השנה. בחודשים אלו קיימת שונות נמוכה יותר בין טמפ' היומיות באותו החודש ולכן המודל יוכל לזהות טוב יותר את המגמה הכללית ולפסק תחזיות מדויקות יותר. לעומת זאת, בשאר החודשים קיימת שונות גבוהה יותר בין הטמפ' היומיות הנמדדות, מה שיכול להוביל לתחזיות פחות מדויקות.



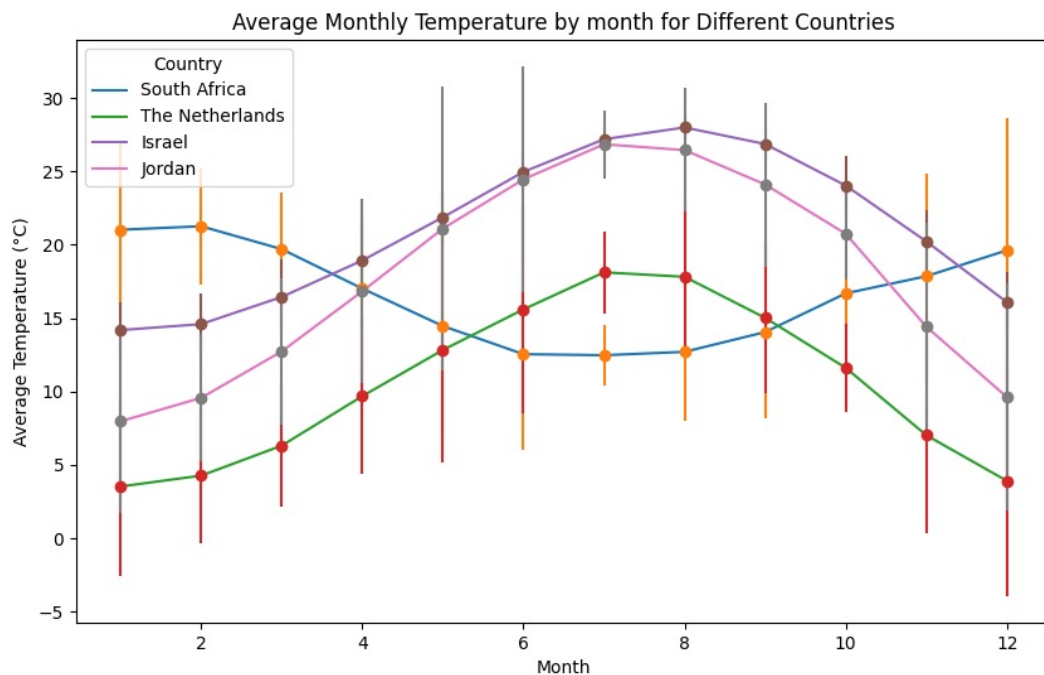
3.2.4 הגרף המוצג מטה מציג את הטמפ' החודשיות לאורך השנה במדינות ישראל, ירדן, דרום אפריקה והולנד.

מהגרף ניתן לראות שלא כל המדינות חולקות את אותו דפוס טמפרטורות ממוצע לפי חודשי השנה. ישנן דמיון בין דפוסי הטמפרטורות של ישראל וירדן, אך דפוסים שונים לגמרי עבור דרום אפריקה או סדר גודל של טמפ' שונה בהפרש ניכר עבור הולנד.

עבור ישראל וירדן, ניכרת מגמה דומה של עלייה בטמפרטורות ממוצעות באביב (מרץ-מאי) עד לכ-30 מעלות, שמגיעה לשיא בקיץ (יוני-אוגוסט), ואז ירידה בטמפרטורות בסתיו (ספטמבר-נובמבר) והחורף (דצמבר-פברואר) אל בין 12 ל-15 מעלות. דפוס זה מצביע על אקלים ממוזג ים-תיכוני דומה במדינות אלו.

לעומת זאת, בדרום אפריקה מופיעה מגמה הפוכה, עם טמפרטורות גבוהות בחורף (יוני-אוגוסט) וטמפרטורות נמוכות יותר בקיץ (דצמבר-פברואר), המאפיינת אקלים טרופי, וכן בהולנד, שם ניכר שקיימת מגמה דומה לאורך השנה, אך קיים הפרש גבוה בין הטמפרטורות בהולנד לטמפרטורות בישראל אשר מגיעות בהולנד לכ-17 בשיא ו-31 בשיא החורף.

לפיכך, ניתן לצפות שמודל פולינומי שמותאם לנתוני ישראל יתאים גם היטב לחיזוי טמפרטורות בירדן, מכיוון שהם חולקים מגמה עונתית דומה. אך מודל זה לא יתאים כל כך טוב לחיזוי בדרום אפריקה בשל המגמה השונה לחלוטין שם וכן בהולנד עקב הפרשי הטמפ'.




3.2.5 הגרף המוצג מטה מציג את מידת השגיאות בחיזוי המודל עבור דרגות שונות של הפולינום עליו המודל מבוסס.

מהגרף וערכי שגיאת הבחינה, ניתן לראות שהשגיאה יורדת ככל שדרגת הפולינום עולה מ-1 ל-4, ומעבר לדרגה 5, שגיאת הבחינה מתחילה לעלות שוב. זה מרמז שפולינום מדרגה 4 או 5 משיג את test error הנמוך ביותר ומספק ככל הנראה את ההתאמה הטובה ביותר לנתונים.

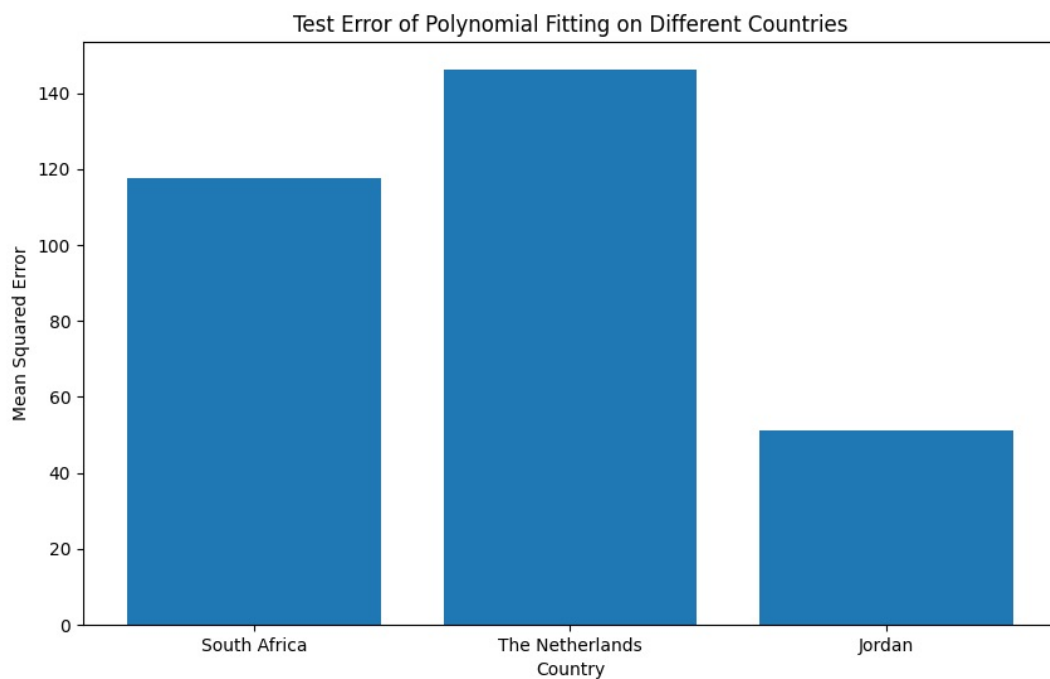
על פי העיקרון של בחירת המודל הפשוט ביותר כאשר מספר מודלים משיגים ביצועים דומים, נבחר בפולינום מדרגה 4 ($k=4$) כהתאמה הטובה ביותר לנתונים, מכיוון שהוא בעל שגיאת הבחינה הנמוכה ביותר מבין כל הדרגות שנבחנו.

עם זאת, חשוב לציין שההבדל בשגיאת הבחינה בין דרגות 3 ($k=3$) ו-4 הוא יחסית קטן. לכן, פולינום מדרגה 3 יכול גם להיחשב כמועמד פוטנציאלי.

לסיכום, על בסיס המידע שסופק, הפולינום מדרגה 4 ($k=4$) נראה כהתאמה הטובה ביותר לנתונים, עם שגיאת הבחינה הנמוכה ביותר. עם זאת, פולינום מדרגה 3 ($k=3$) יכול גם להיות בחירה סבירה, בהתחשב בשגיאת הבחינה הגבוהה במעט אך עדיין נמוכה יחסית שלו ובמורכבות הפוטנציאלית הנמוכה יותר לעומת דרגה 4.



3.2.6 הגרף מציג את שגיאת המודל עבור חזוי טמפרטורות ממוצעות במדינות שונות בעזרת מודל אשר נבנה על סמך נתוני ישראל. התוצאות מראות כי המודל מצליח לנבא טוב יותר בירדן בשל הדמיון בדפוסי הטמפרטורות בין ישראל לירדן. לעומת זאת, השגיאה בהולנד גבוהה מכיוון שההבדל בטמפרטורות המקסימליות משמעותי – בישראל הטמפרטורה בשיא הקיץ מגיעה ל-30 מעלות, בעוד שבהולנד היא מגיעה רק ל-17 מעלות. בדרום אפריקה השגיאה גבוהה אף היא, בשל האקלים הטרופי השונה. התוצאות מתאימות בצורה יפה אל הדפוסים שזיהינו בתשובה לשאלה 3. מהגרף המתקבל נובע כי עבור מדינות עם אקלים ודפוסי טמפרטורות שונים, עדיף להתאים מודלים נפרדים המבוססים על נתונין המקומיים.



בזמן העבודה התכנותית הפרקטית השתמשתי ב-3.5 chatgpt בעזרה בסינטקס ושימוש בספריות matplotlib וsklearn כאשר השתמשתי בהם. כמו כן, נעזרתי בו על מנת למצוא באגים או תקלות בקוד כאשר היו כאלה ולא הצלחתי למצוא את השורה הבעייתית בקוד.